

## 基于残差机制的图卷积神经网络

### 1、算法介绍

基于现有的 GCN 网络架构，设置两层卷积层为隐藏层，接受图结构  $G=\langle V, E \rangle$  及图的顶点特征矩阵  $X^{(0)} \in R^{|V| \times F_0}$  作为输入，针对赛事要求，即对给定数据集，在不损失计算精度（计算的中间过程及其最后结果应全部采用 32 位浮点数精度）的情况下，以尽可能短的时间完成 GCN 推理的计算。我们引入残差机制，在每一个卷积层的输出中加入上一阶段的节点特征，从而起到自特征凸显作用。同时，为控制自特征的影响程度，我们引入一个超参数  $\alpha$  调节特征值。

### 2、设计思路

按照赛事要求，要保证计算精度，且要尽可能短的时间完成，那么就不能加入新的计算量。而计算时间主要集中在对节点信息的聚合过程中，该过程由固定公式确定，因此我们转换思路，提高模型的计算精度，且不改变原有的计算时间。而经过调研后发现，节点自身的特征才是最为重要的特征，因此，我们想到了残差机制，并将其应用在节点特征中。但同时想到自身特征的影响不应该大于节点聚合的特征，因此，我们引入一个超参数  $\alpha$  作为控制。

### 3、算法优化

对于 GCN 的算法优化体现在节点特征的增强方面，引入残差机制，并设置控制系数  $\alpha$ 。实现相同时间内的高精度推导。

### 4、详细算法设计与实现

#### 全局变量和数据结构

- v\_num 和 e\_num: 顶点和边的数量。
- F0, F1, F2: 各层特征维度。
- edge\_index 和 edge\_val: 邻接列表和边权值。
- degree: 每个顶点的度数。
- raw\_graph: 原始图数据。

#### 数据读取函数

- readGraph(char \*fname): 从指定文件中读取顶点和边的信息，构建原始图数据。
- readFloat(char \*fname, float \*&dst, int num): 从指定文件中读取浮点数数据，存储到 dst 中。

#### 数据预处理

- raw\_graph\_to\_AdjacencyList(): 将原始图数据转换为邻接列表形式，并计算每个顶点的度数。
- edgeNormalization(): 根据度数对边权值进行归一化处理。

## 初始化和矩阵操作

- `initFloat(float *&dst, int num)`: 初始化浮点数数组 `dst`, 并将其值设为 0。
- `XW(int in_dim, int out_dim, float *in_X, float *out_X, float *W)`: 实现特征矩阵 `in_X` 与权重矩阵 `W` 的矩阵乘法, 结果存储在 `out_X` 中。
- `AX(int dim, float *in_X, float *out_X)`: 实现邻接矩阵 `A` 与特征矩阵 `in_X` 的矩阵乘法, 结果存储在 `out_X` 中。
- `ReLU(int dim, float *X)`: 对输入矩阵 `X` 应用 ReLU 激活函数。
- `LogSoftmax(int dim, float *X)`: 对输入矩阵 `X` 应用 LogSoftmax 激活函数。
- `MaxRowSum(float *X, int dim)`: 计算输入矩阵 `X` 每行的和, 并返回最大值。

## 内存释放

- `freeFloats()`: 释放所有动态分配的浮点数数组内存。

## 残差块函数

- `residualBlock(int in_dim, int out_dim, float *in_X, float *out_X, float *W, bool apply_relu)`: 实现带有残差连接的网络层, 将输入 `in_X` 经过权重矩阵 `W` 处理后, 加入残差连接, 结果存储在 `out_X` 中。

## 主函数

- `main(int argc, char **argv)`: 读取输入参数, 初始化数据, 调用各模块进行计算, 输出结果并计时, 最后释放内存。